

# Regresión Lineal Simple

La regresión lineal es un campo de estudio que enfatiza la **relación estadística** entre dos **variables continuas** conocidas como **variables de predicción y respuesta** . (Nota: cuando hay más de una variable predictora, se convierte en regresión lineal múltiple).

- La variable predictora se denota con mayor frecuencia como **x** y también se conoce como variable independiente.
- La variable de respuesta se denota con mayor frecuencia como **y** y también se conoce como variable dependiente

# Regresión Lineal Simple

Un modelo de regresión es un modelo que permite describir como influye una variable  $X$  sobre otra variable  $Y$  .

$X$ : Variable independiente o explicativa o exógena

$Y$ : Variable dependiente o respuesta o endógena

El objetivo es obtener estimaciones razonables de  $Y$  para distintos valores de  $X$  a partir de una muestra de  $n$  pares de valores  $(x_1, y_1), \dots, (x_n, y_n)$ .

# Regresión Lineal Simple

## Ejemplos

- Estudiar como influye la **estatura del padre** sobre la **estatura del hijo**.
- Estimar el **precio de una vivienda** en función de su **superficie**.
- Predecir la **tasa de paro** para cada **edad**.
- Aproximar la **calificación obtenida en una materia** según el **número de horas de estudio semanal**.
- Prever el tiempo de computación de un programa en función de la **velocidad del procesador**.

# Regresión Lineal Simple

## Tipos de relación

Determinista: Conocido el valor de X, el valor de Y queda perfectamente establecido. Son del tipo:

$$y = f(x)$$

Ejemplo: La relación existente entre la temperatura en grados centígrados (X) y grados Fahrenheit (Y ) es:

$$y = 1,8x + 32$$

# Regresión Lineal Simple

## Tipos de relación

No determinista: Conocido el valor de X, el valor de Y no queda perfectamente establecido. Son del tipo:

$$y = f(x) + u$$

donde u es una perturbación desconocida (variable aleatoria).

Ejemplo: Se tiene una muestra del volumen de producción (X) y el costo total (Y ) asociado a un producto en un grupo de empresas.

# Regresión Lineal Simple

## Tipos de relación

Lineal: Cuando la función  $f(x)$  es lineal,

$$f(x) = \beta_0 + \beta_1 x$$

Si  $\beta_1 > 0$  hay relación lineal positiva.

Si  $\beta_1 < 0$  hay relación lineal negativa.

# Regresión Lineal Simple

## Tipos de relación

No lineal: Cuando la función  $f(x)$  no es lineal. Por ejemplo,

$$f(x) = \log(x)$$

$$f(x) = x^2 + 3, \dots$$

Ausencia de relación: Cuando  $f(x) = 0$

# Ejemplo: Regresión Lineal Simple

Los datos de la producción de trigo en toneladas y el precio del kilo de harina en córdobas en la década de los 2000 en Nicaragua fueron:

|                     |    |    |    |    |    |    |    |    |    |    |
|---------------------|----|----|----|----|----|----|----|----|----|----|
| Producción de trigo | 30 | 28 | 32 | 25 | 25 | 25 | 22 | 24 | 35 | 40 |
| Precio de la harina | 25 | 30 | 27 | 40 | 42 | 40 | 50 | 45 | 30 | 25 |

## Solución:

Lo primero que debemos hacer es identificar cuál es la **variable dependiente (Y)** y la **variable independiente (X)**

En este caso la variable independiente es la **producción de trigo**, pues dependiendo de la producción varía el precio de la harina, cuando se produce más trigo la harina es más barata y es más cara cuando la producción de trigo baja. Entonces, la variable dependiente es el **precio de la harina**

Dividiremos el problema en tres fases para que sea más sencilla su solución

- Fase 1: Encontrar la Covarianza  $S_{x,y}$
- Fase 2: Encontrar la Correlación  $\rho_{x,y}$
- Fase 3: Encontrar  $\beta_0$  y  $\beta_1$

# Ejemplo: Regresión Lineal Simple

## Fase 1: Encontrar la Covarianza $S_{x,y}$

$$S_{x,y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n - 1}$$

Como vemos para encontrar  $S_{x,y}$  es necesario calcular antes la media aritmética de x y la media de y, lo calculamos como hacíamos en estadística descriptiva, sumando todos sus valores y dividiendo entre el número total de valores

$$\bar{x} = (30+28+32+25+25+25+22+24+35+40) / 10 = 28.6$$

$$\bar{y} = (25+30+27+40+42+40+50+45+30+25) / 10 = 35.4$$

Ya que hemos calculado las medias dividiremos la fórmula en pasos más pequeños para resolverlo de un modo más simple

### A continuación:

- Agregaremos la columna  $x_i - \bar{x}$  a la tabla, en la cual a cada valor de  $x$  le restaremos su media
- Agregaremos la columna  $y_i - \bar{y}$  a la tabla, en la cual a cada valor de  $y$  le restaremos su media
- Agregaremos la columna  $(x_i - \bar{x})(y_i - \bar{y})$  a la tabla, en la cual Multiplicaremos los valores de las dos columnas agregadas antes.
- Encontramos  $S_{x,y}$  dividiendo el resultado de la suma de la última columna que agregamos entre el total de observaciones - 1 (9 en este caso)

# Ejemplo: Regresión Lineal Simple

## Fase 1: Encontrar la Covarianza $S_{x,y}$

a) Agregaremos la columna  $x_i - \bar{x}$  a la tabla, en la cual a cada valor de  $x$  le restaremos su media  $\bar{x} = 28.6$

| Trigo (x) | Harina(y) | $x_i - \bar{x}$ |
|-----------|-----------|-----------------|
| 30        | 25        | 1.4             |
| 28        | 30        | -0.6            |
| 32        | 27        | 3.4             |
| 25        | 40        | -3.6            |
| 25        | 42        | -3.6            |
| 25        | 40        | -3.6            |
| 22        | 50        | -6.6            |
| 24        | 45        | -4.6            |
| 35        | 30        | 6.4             |
| 40        | 25        | 11.4            |

b) Agregaremos la columna  $y_i - \bar{y}$  a la tabla, en la cual a cada valor de  $y$  le restaremos su media  $\bar{y} = 35.4$

| Trigo (x) | Harina(y) | $x_i - \bar{x}$ | $y_i - \bar{y}$ |
|-----------|-----------|-----------------|-----------------|
| 30        | 25        | 1.4             | -10.4           |
| 28        | 30        | -0.6            | -5.4            |
| 32        | 27        | 3.4             | -8.4            |
| 25        | 40        | -3.6            | 4.6             |
| 25        | 42        | -3.6            | 6.6             |
| 25        | 40        | -3.6            | 4.6             |
| 22        | 50        | -6.6            | 14.6            |
| 24        | 45        | -4.6            | 9.6             |
| 35        | 30        | 6.4             | -5.4            |
| 40        | 25        | 11.4            | -10.4           |

# Ejemplo: Regresión Lineal Simple

## Fase 1: Encontrar la Covarianza $S_{x,y}$

- c) Agregaremos la columna  $(x_i - \bar{x})(y_i - \bar{y})$  a la tabla, en la cual Multiplicaremos los valores de las dos columnas agregadas antes.

| Trigo (x) | Harina (y) | $x_i - \bar{x}$ | $y_i - \bar{y}$ | $(x_i - \bar{x})(y_i - \bar{y})$ |
|-----------|------------|-----------------|-----------------|----------------------------------|
| 30        | 25         | 1.4             | -10.4           | -14.56                           |
| 28        | 30         | -0.6            | -5.4            | 3.24                             |
| 32        | 27         | 3.4             | -8.4            | -28.56                           |
| 25        | 40         | -3.6            | 4.6             | -16.56                           |
| 25        | 42         | -3.6            | 6.6             | -23.76                           |
| 25        | 40         | -3.6            | 4.6             | -16.56                           |
| 22        | 50         | -6.6            | 14.6            | -96.36                           |
| 24        | 45         | -4.6            | 9.6             | -44.16                           |
| 35        | 30         | 6.4             | -5.4            | -34.56                           |
| 40        | 25         | 11.4            | -10.4           | -118.56                          |
|           |            |                 |                 | <b>-390.4</b>                    |

*Sumamos los valores de la columna agregada recientemente y obtendremos*

$$\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = -390.4$$

- d) Encontramos  $S_{x,y}$  dividiendo el resultado de la suma de la última columna que agregamos entre el total de observaciones - 1 (9 en este caso)

$$S_{x,y} = -390.4 / 9 = -43.37777778$$

# Ejemplo: Regresión Lineal Simple

## Fase 2: Encontrar la Correlación $\rho_{x,y}$

$$\rho_{x,y} = \frac{S_{x,y}}{S_x S_y}$$

Como podemos ver, para calcular la correlación necesitamos de la covarianza, de la **varianza de x** y la **varianza de y**, ya hemos calculado la covarianza en la fase uno, entonces es necesario calcular la **varianza de x** y la **varianza de y**

$$S_x = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$

Calcular la varianza tanto de x como de y requiere de la misma fórmula, sólo variaremos los datos. Como ya tenemos en dos columnas  $x_i - \bar{x}$  y  $y_i - \bar{y}$  respectivamente, ahora sólo resta agregar dos columnas nuevas que contendrán

$(x_i - \bar{x})^2$  = los valores de  $x_i - \bar{x}$  elevados al cuadrado

$(y_i - \bar{y})^2$  = los valores de  $y_i - \bar{y}$  elevados al cuadrado

$$S_y = \sqrt{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n - 1}}$$

Sumamos cada columna, dividimos entre 9 (el total de casos -1) y sacamos raíz cuadrada en cada caso

# Ejemplo: Regresión Lineal Simple

## Fase 2: Encontrar la Correlación $\rho_{x,y}$

| Trigo (x) | Harina (y) | $x_i - \bar{x}$ | $y_i - \bar{y}$ | $(x_i - \bar{x})(y_i - \bar{y})$ | $(x_i - \bar{x})^2$ | $(y_i - \bar{y})^2$ |
|-----------|------------|-----------------|-----------------|----------------------------------|---------------------|---------------------|
| 30        | 25         | 1.4             | -10.4           | -14.56                           | 1.96                | 108.16              |
| 28        | 30         | -0.6            | -5.4            | 3.24                             | 0.36                | 29.16               |
| 32        | 27         | 3.4             | -8.4            | -28.56                           | 11.56               | 70.56               |
| 25        | 40         | -3.6            | 4.6             | -16.56                           | 12.96               | 21.16               |
| 25        | 42         | -3.6            | 6.6             | -23.76                           | 12.96               | 43.56               |
| 25        | 40         | -3.6            | 4.6             | -16.56                           | 12.96               | 21.16               |
| 22        | 50         | -6.6            | 14.6            | -96.36                           | 43.56               | 213.16              |
| 24        | 45         | -4.6            | 9.6             | -44.16                           | 21.16               | 92.16               |
| 35        | 30         | 6.4             | -5.4            | -34.56                           | 40.96               | 29.16               |
| 40        | 25         | 11.4            | -10.4           | -118.56                          | 129.96              | 108.16              |
|           |            |                 |                 | <b>-390.4</b>                    | <b>288.4</b>        | <b>736.4</b>        |

$$S_x = \sqrt{\frac{288.4}{10-1}} = 5.661$$

$$S_y = \sqrt{\frac{736.4}{10-1}} = 9.0456$$

Ahora que calculamos todas las varianzas sustituimos los valores en la fórmula de la correlación y resolvemos

$$\rho_{x,y} = \frac{-43.37777778}{(5.661)(9.0456)} = -0.8471402$$

# Ejemplo: Regresión Lineal Simple

## Fase 3: Encontrar $\beta_0$ y $\beta_1$

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

$$\beta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Para encontrar  $\beta_0$  necesitaremos 3 elementos y ya conocemos dos de ellos,  $\bar{y} = 35.4$  y  $\bar{x} = 28.6$  fueron calculados en la fase 1, sin embargo falta encontrar  $\beta_1$ , por lo cual vamos a trabajar antes con la segunda fórmula

Aunque la fórmula de  $\beta_1$  a primera vista puede resultar imponente, lo cierto es que ya casi la tenemos resuelta pues en la fase 1 encontramos  $\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = -390.4$

Y en la fase 2 encontramos  $\sum_{i=1}^n (x_i - \bar{x})^2 = 288.4$

Por tanto para encontrar  $\beta_1$  sólo queda dividir

# Ejemplo: Regresión Lineal Simple

## Fase 3: Encontrar $\beta_0$ y $\beta_1$

$$\beta_1 = \frac{-390.4}{288.4} = -1.3537$$

$$\beta_0 = 35.4 - (-1.3537)(28.6)$$

$$\beta_0 = 74.115$$

Acabadas las operaciones yo puedo formar mi ecuación lineal de predicción de la forma  
 $f(x) = \beta_0 + \beta_1 x$

$$**y = 74.115 - 1.3537 x**$$

Entonces, si queremos predecir el precio de la harina, debemos colocar en x el valor de la producción de trigo, al resolver la ecuación tendremos nuestra predicción del futuro precio de la harina